Obliczenia naukowe, lista 2

Jakub Retmańczyk

7 listopada 2026

1 Zadanie 1

Powtórzyłem zadanie 4 z listy 1 dla danych bez ostatniej cyfry w x_4 i x_5, czyli dla $x_4 = 0.577215664$ i $x_5 = 0.301029995$. Iloczyn skalarny policzyłem tymi samymi czterema metodami sumowania, a wartość dokładną dla zmienionych danych wyznaczyłem w `BigFloat`.

Tabela 1: Iloczyn skalarny dla danych pierwotnych i zmienionych.

Metoda	**Float32**		**Float64**	
	pierwotne	zmienione	pierwotne	zmienione
(a) w przód	-0.4999443	-0.4999443	$1.025 \cdot 10^{-10}$	$-4.29634274 \cdot 10^{-3}$
(b) w tył	-0.4543457	-0.4543457	$-1.564 \cdot 10^{-10}$	$-4.29634300 \cdot 10^{-3}$
(c) od największych	-0.5	-0.5	0	$-4.29634284 \cdot 10^{-3}$
(d) od najmniejszych	-0.5	-0.5	0	$-4.29634284 \cdot 10^{-3}$
Wartość dokładna			$-1.007 \cdot 10^{-11}$	$-4.29634319 \cdot 10^{-3}$

Interpretacja wyników

- Względna zmiana danych wynosi około $2 \cdot 10^{-9}$, a wartość dokładna iloczynu zmieniła się z $-1.0 \cdot 10^{-11}$ na $-4.3 \cdot 10^{-3}$, czyli o ponad 8 rzędów wielkości. Niemal całą tę różnicę daje składnik $y_4 \Delta x_4$, ponieważ $y_4 \approx 4.8 \cdot 10^6$.
- Niewielka względna zmiana danych powoduje więc duże odkształcenie wyniku, czyli zadanie jest bardzo źle uwarunkowane. Dla danych pierwotnych wskaźnik uwarunkowania $\sum |x_i y_i| / |\sum x_i y_i|$ wynosi około $5.5 \cdot 10^{17}$.
- W `Float64` błąd bezwzględny jest podobny jak poprzednio (rzędu 10^{-10}), ale sam wynik jest dużo większy, dlatego wszystkie metody dają teraz około 7 poprawnych cyfr. Dla danych pierwotnych wyniki składały się z samych błędów zaokrągleń, a metoda (a) dała nawet przeciwny znak.
- W `Float32` wyniki w ogóle się nie zmieniły. Po konwersji x_4 jest takie samo w obu wersjach, a x_5 różni się tylko ostatnim bitem, co nie ma znaczenia przy składnikach rzędu 10^6. Wyniki nadal są błędne, bo wynoszą około -0.5 zamiast $-4.3 \cdot 10^{-3}$.

2 Zadanie 2

Układ $Ax = b$, gdzie $b = Ax$ i $x = (1, \ldots, 1)^T$, rozwiązałem na dwa sposoby: eliminacją Gaussa (`A\b`) i przez macierz odwrotną (`inv(A)*b`). W tabelach podaję błąd względny $\|\tilde{x} - x\|_2 / \|x\|_2$.

Tabela 2: Macierze Hilberta H_n.

n	`cond`	`rank`	**Gauss**	**inv**
2	$1.9 \cdot 10^{1}$	2	$5.7 \cdot 10^{-16}$	$1.1 \cdot 10^{-15}$
4	$1.6 \cdot 10^{4}$	4	$3.6 \cdot 10^{-13}$	$2.4 \cdot 10^{-13}$
6	$1.5 \cdot 10^{7}$	6	$2.6 \cdot 10^{-10}$	$2.6 \cdot 10^{-10}$
8	$1.5 \cdot 10^{10}$	8	$3.8 \cdot 10^{-7}$	$4.0 \cdot 10^{-7}$
10	$1.6 \cdot 10^{13}$	10	$2.1 \cdot 10^{-4}$	$2.5 \cdot 10^{-4}$
12	$1.7 \cdot 10^{16}$	11	$4.7 \cdot 10^{-2}$	$1.8 \cdot 10^{-1}$
14	$1.9 \cdot 10^{17}$	11	3.0	3.5
16	$4.3 \cdot 10^{17}$	12	4.6	5.9
18	$3.6 \cdot 10^{19}$	12	5.4	$1.2 \cdot 10^{1}$
20	$1.9 \cdot 10^{18}$	13	6.6	6.3
25	$2.9 \cdot 10^{19}$	13	$1.6 \cdot 10^{2}$	$9.3 \cdot 10^{1}$
30	$6.5 \cdot 10^{18}$	14	$1.1 \cdot 10^{1}$	$1.1 \cdot 10^{2}$

Tabela 3: Macierze losowe R_n (jedno losowanie, ziarno 1234).

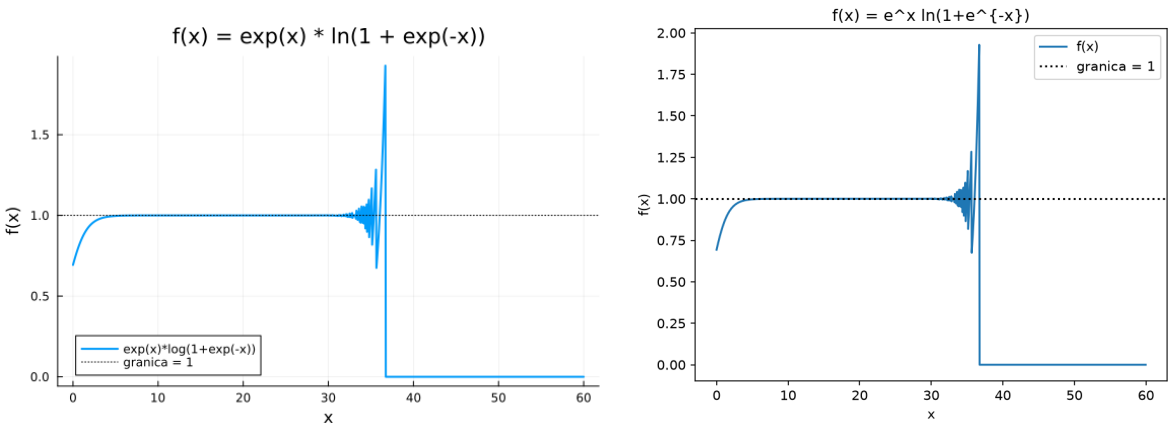
	$n = 5$		$n = 10$		$n = 20$	
c	**Gauss**	**inv**	**Gauss**	**inv**	**Gauss**	**inv**
1	$2.7 \cdot 10^{-16}$	$1.2 \cdot 10^{-16}$	$2.0 \cdot 10^{-16}$	$1.8 \cdot 10^{-16}$	$5.9 \cdot 10^{-16}$	$4.2 \cdot 10^{-16}$
10	$2.4 \cdot 10^{-16}$	$1.4 \cdot 10^{-16}$	$3.1 \cdot 10^{-16}$	$4.4 \cdot 10^{-16}$	$5.6 \cdot 10^{-16}$	$3.4 \cdot 10^{-16}$
10^{3}	$9.0 \cdot 10^{-15}$	$8.7 \cdot 10^{-15}$	$5.4 \cdot 10^{-16}$	$1.7 \cdot 10^{-15}$	$3.6 \cdot 10^{-14}$	$3.9 \cdot 10^{-14}$
10^{7}	$1.1 \cdot 10^{-11}$	$3.6 \cdot 10^{-11}$	$9.6 \cdot 10^{-11}$	$1.2 \cdot 10^{-10}$	$5.0 \cdot 10^{-11}$	$8.5 \cdot 10^{-11}$
10^{12}	$1.8 \cdot 10^{-5}$	$1.8 \cdot 10^{-5}$	$1.0 \cdot 10^{-6}$	$2.4 \cdot 10^{-6}$	$3.0 \cdot 10^{-6}$	$5.9 \cdot 10^{-6}$
10^{16}	$1.2 \cdot 10^{-1}$	$1.6 \cdot 10^{-1}$	$5.7 \cdot 10^{-1}$	$6.1 \cdot 10^{-1}$	2.0	1.8

Interpretacja wyników

- Dla macierzy R_n błąd rośnie wraz z c, od około 10^{-16} dla $c = 1$ do wartości między 0.12 a 2.0 dla $c = 10^{16}$, więc przy największym c wynik nie ma już poprawnych cyfr. O rzędzie błędu decyduje c, a rozmiar macierzy nie ma systematycznego wpływu. Tylko dla $c = 10^{16}$ błąd rósł z n, ale to wynik jednego losowania. Od $c = 10^{3}$ błąd jest mniejszy niż $c \cdot$ macheps.
- Dla macierzy Hilberta błąd rośnie bardzo szybko, ponieważ wskaźnik uwarunkowania zwiększa się o około 3 rzędy wielkości na każde dwa stopnie. Dla $n = 10$ zostają 3 lub 4 poprawne cyfry, dla $n = 12$ błąd wynosi już 0.05 (Gauss) i 0.18 (`inv`), a od $n = 14$ przekracza 1, więc wynik nie ma poprawnych cyfr.
- Macierz H_n jest nieosobliwa, a mimo to od $n = 12$ funkcja `rank` zwraca wartość mniejszą niż n. Wartości `cond` dla $n \geq 14$ też są niewiarygodne, bo dla $n = 30$ otrzymałem mniej niż dla $n = 25$. Podobnie jest dla R_n przy $c = 10^{16}$. Rząd spadł tam o 1 (do 4, 9 i 19), a `cond` wyniosło $1.2 \cdot 10^{16}$, $1.0 \cdot 10^{16}$ i $9.0 \cdot 10^{15}$.
- Żadna z metod nie jest wyraźnie dokładniejsza. Eliminacja Gaussa dała mniejszy błąd w 18 z 30 testów, a błędy obu metod były zwykle porównywalne, więc o dokładności decyduje przede wszystkim uwarunkowanie macierzy. W praktyce wybrałbym `A\b`, bo nie trzeba wtedy wyznaczać całej macierzy odwrotnej.

3 Zadanie 3

Podstawiając $t = e^{-x}$, otrzymujemy $\lim_{x\to\infty} f(x) = \lim_{t\to 0^+} \ln(1+t)/t = 1$. Wykres funkcji $f(x) = e^{x}\ln(1+e^{-x})$ narysowałem w Julii (Plots) i w Pythonie (matplotlib).



Rysunek 1: Wykres $f(x)$ w Julii (po lewej) i w Pythonie (po prawej).

Tabela 4: Wartości $f(x)$ w `Float64`.

x	10	20	30	36	36.7	37
$f(x)$	0.9999773007	1.0000000328	0.9989799652	0.9572857056	1.9277366815	0

Interpretacja wyników

- Oba programy rysują taki sam wykres, więc przyczyną zjawiska jest arytmetyka `Float64`. Do około $x = 30$ wykres zgadza się z granicą, potem zaczyna oscylować (dla x między 35 a 36 w zakresie od 0.67 do 1.33), tuż przed $x = 36.74$ dochodzi prawie do 2, a dalej jest stale równy 0, mimo że granica wynosi 1.
- Oscylacje wynikają z utraty cyfr znaczących. Dla dużych x w sumie $1 + e^{-x}$ zostaje tylko kilka bitów z e^{-x}, a mnożenie przez e^x powiększa powstały błąd. Dla $x \in (35.64, 36.74)$ suma zaokrągla się do $1 + 2^{-52}$, więc $f(x) \approx 2^{-52}e^x$ rośnie od 0.67 do 2.
- Dla $x > 36.74$ mamy $e^{-x} < 2^{-53}$, więc $\mathrm{fl}(1 + e^{-x}) = 1$, $\ln 1 = 0$ i $f(x) = 0$.

4 Zadanie 4

Pierwiastki z_k policzyłem funkcją `roots` z pakietu Polynomials i posortowałem według części rzeczywistej. W przypadku (b) P oznacza wielomian zaburzony, a p nadal wielomian oryginalny.

Tabela 5: Sprawdzenie pierwiastków wielomianu Wilkinsona.

	(a) współczynniki oryginalne			**(b)** $-210 \to -210 - 2^{-23}$		
k	$\lvert P(z_k)\rvert$	$\lvert p(z_k)\rvert$	$\lvert z_k - k\rvert$	$\lvert P(z_k)\rvert$	$\lvert p(z_k)\rvert$	$\lvert z_k - k\rvert$
1	$1.6 \cdot 10^{3}$	$2.0 \cdot 10^{3}$	$1.7 \cdot 10^{-14}$	$1.0 \cdot 10^{4}$	$9.4 \cdot 10^{3}$	$7.7 \cdot 10^{-14}$
2	$7.0 \cdot 10^{3}$	$5.5 \cdot 10^{3}$	$8.6 \cdot 10^{-13}$	$5.6 \cdot 10^{4}$	$5.3 \cdot 10^{4}$	$8.3 \cdot 10^{-12}$
3	$3.6 \cdot 10^{5}$	$2.4 \cdot 10^{5}$	$3.4 \cdot 10^{-10}$	$8.1 \cdot 10^{5}$	$6.3 \cdot 10^{5}$	$8.9 \cdot 10^{-10}$
4	$4.1 \cdot 10^{6}$	$3.8 \cdot 10^{6}$	$3.0 \cdot 10^{-8}$	$8.1 \cdot 10^{6}$	$7.0 \cdot 10^{6}$	$5.6 \cdot 10^{-8}$
5	$3.1 \cdot 10^{7}$	$2.8 \cdot 10^{7}$	$8.8 \cdot 10^{-7}$	$3.9 \cdot 10^{7}$	$3.4 \cdot 10^{7}$	$1.1 \cdot 10^{-6}$
6	$1.4 \cdot 10^{8}$	$1.4 \cdot 10^{8}$	$1.3 \cdot 10^{-5}$	$1.5 \cdot 10^{8}$	$5.4 \cdot 10^{7}$	$5.2 \cdot 10^{-6}$
7	$5.2 \cdot 10^{8}$	$5.3 \cdot 10^{8}$	$1.2 \cdot 10^{-4}$	$4.1 \cdot 10^{8}$	$1.0 \cdot 10^{9}$	$2.3 \cdot 10^{-4}$
8	$1.7 \cdot 10^{9}$	$1.7 \cdot 10^{9}$	$7.1 \cdot 10^{-4}$	$5.0 \cdot 10^{8}$	$1.7 \cdot 10^{10}$	$7.0 \cdot 10^{-3}$
9	$5.1 \cdot 10^{9}$	$4.9 \cdot 10^{9}$	$3.0 \cdot 10^{-3}$	$1.2 \cdot 10^{9}$	$1.3 \cdot 10^{11}$	$8.2 \cdot 10^{-2}$
10	$1.2 \cdot 10^{10}$	$1.2 \cdot 10^{10}$	$9.4 \cdot 10^{-3}$	$1.7 \cdot 10^{9}$	$1.5 \cdot 10^{12}$	$6.5 \cdot 10^{-1}$
11	$3.1 \cdot 10^{10}$	$3.0 \cdot 10^{10}$	$2.3 \cdot 10^{-2}$	$1.7 \cdot 10^{9}$	$1.5 \cdot 10^{12}$	1.1
12	$6.1 \cdot 10^{10}$	$6.4 \cdot 10^{10}$	$4.1 \cdot 10^{-2}$	$1.9 \cdot 10^{10}$	$3.3 \cdot 10^{13}$	1.7
13	$1.5 \cdot 10^{11}$	$1.5 \cdot 10^{11}$	$6.0 \cdot 10^{-2}$	$1.9 \cdot 10^{10}$	$3.3 \cdot 10^{13}$	2.0
14	$3.1 \cdot 10^{11}$	$2.8 \cdot 10^{11}$	$6.5 \cdot 10^{-2}$	$2.8 \cdot 10^{11}$	$9.5 \cdot 10^{14}$	2.5
15	$5.0 \cdot 10^{11}$	$5.9 \cdot 10^{11}$	$5.4 \cdot 10^{-2}$	$2.8 \cdot 10^{11}$	$9.5 \cdot 10^{14}$	2.7
16	$9.4 \cdot 10^{11}$	$1.1 \cdot 10^{12}$	$3.6 \cdot 10^{-2}$	$1.1 \cdot 10^{12}$	$2.7 \cdot 10^{16}$	2.9
17	$2.4 \cdot 10^{12}$	$2.1 \cdot 10^{12}$	$1.7 \cdot 10^{-2}$	$1.1 \cdot 10^{12}$	$2.7 \cdot 10^{16}$	2.8
18	$5.7 \cdot 10^{12}$	$3.9 \cdot 10^{12}$	$5.6 \cdot 10^{-3}$	$6.9 \cdot 10^{12}$	$4.3 \cdot 10^{17}$	2.5
19	$7.7 \cdot 10^{12}$	$7.4 \cdot 10^{12}$	$1.1 \cdot 10^{-3}$	$6.9 \cdot 10^{12}$	$4.3 \cdot 10^{17}$	2.0
20	$1.2 \cdot 10^{13}$	$1.4 \cdot 10^{13}$	$1.1 \cdot 10^{-4}$	$9.7 \cdot 10^{11}$	$1.4 \cdot 10^{18}$	$8.5 \cdot 10^{-1}$

Interpretacja wyników (a)

- Błąd $|z_k - k|$ rośnie od $1.7 \cdot 10^{-14}$ dla $k = 1$ do $6.5 \cdot 10^{-2}$ dla $k = 14$, a następnie maleje do $1.1 \cdot 10^{-4}$ dla $k = 20$.
- Duże wartości $|P(z_k)|$ i $|p(z_k)|$ nie wynikają z błędów obliczania wielomianu. Wartość $P(z_k)$ policzona w `BigFloat` z dokładnymi współczynnikami jest niemal taka sama jak $|p(z_k)|$. Powodem jest zależność $|p(z_k)| \approx |p'(k)| \cdot |z_k - k|$. Ponieważ $|p'(k)| = (k-1)!\,(20-k)!$ wynosi od $1.3 \cdot 10^{12}$ do $1.2 \cdot 10^{17}$, nawet mały błąd pierwiastka daje bardzo dużą wartość wielomianu.
- Różnice między $|P(z_k)|$ a $|p(z_k)|$ to już błąd obliczania postaci naturalnej, w której składniki sięgają $6.6 \cdot 10^{28}$ i prawie się znoszą. W postaci iloczynowej tego problemu nie ma.
- Pięciu współczynników nie da się zapisać dokładnie w `Float64` (błędy od 16 do 512), ale według obliczeń w `BigFloat` samo to przesuwa pierwiastki najwyżej o $6.2 \cdot 10^{-4}$. Większość błędu z_k pochodzi więc z zaokrągleń w trakcie działania `roots`, które przez złe uwarunkowanie zadania również mocno przesuwają pierwiastki.

Interpretacja wyników (b)

- Zaburzenie współczynnika o $2^{-23} \approx 1.2 \cdot 10^{-7}$ (względnie $5.7 \cdot 10^{-10}$) mocno przesuwa pierwiastki. Dziesięć z nich tworzy pięć par zespolonych: $10.10 \pm 0.64i$, $11.79 \pm 1.65i$, $13.99 \pm 2.52i$, $16.73 \pm 2.81i$, $19.50 \pm 1.94i$, a największy pierwiastek rzeczywisty to 20.85. Największy błąd wynosi 2.91.
- Pierwiastki dla małych k zmieniają się niewiele (do $k = 8$ błąd jest mniejszy niż 10^{-2}). Najbardziej czułe na zaburzenie są pierwiastki od 10 do 20.
- Dla $k \geq 10$ wartość $|P(z_k)|$ jest mniejsza od $|p(z_k)|$ o około 3 do 6 rzędów wielkości. Liczby z_k leżą więc blisko zer wielomianu zaburzonego, ale daleko od zer wielomianu oryginalnego.

5 Zadanie 5

Wykonałem 40 iteracji dla $p_0 = 0.01$ i $r = 3$. W eksperymencie 1 po 10. iteracji obciąłem wynik do 0.722 i liczyłem dalej. Do porównania policzyłem te same iteracje w `BigFloat`.

Tabela 6: Eksperyment 1 (`Float32`, po lewej) i eksperyment 2 (po prawej).

n	**bez obcięcia**	**z obcięciem**	**różnica**	n	**Float32**	**Float64**	**różnica**
10	0.72293	0.72200	$9.3 \cdot 10^{-4}$	10	0.72293	0.72291	$1.6 \cdot 10^{-5}$
12	0.03772	0.03649	$1.2 \cdot 10^{-3}$	15	1.27048	1.27026	$2.2 \cdot 10^{-4}$
15	1.27048	1.25722	$1.3 \cdot 10^{-2}$	20	0.57990	0.59653	$1.7 \cdot 10^{-2}$
20	0.57990	1.30969	0.73	25	1.00708	1.31559	0.31
30	0.75292	1.31918	0.57	30	0.75292	0.37415	0.38
40	0.25861	1.09357	0.83	40	0.25861	0.01161	0.25

Interpretacja wyników

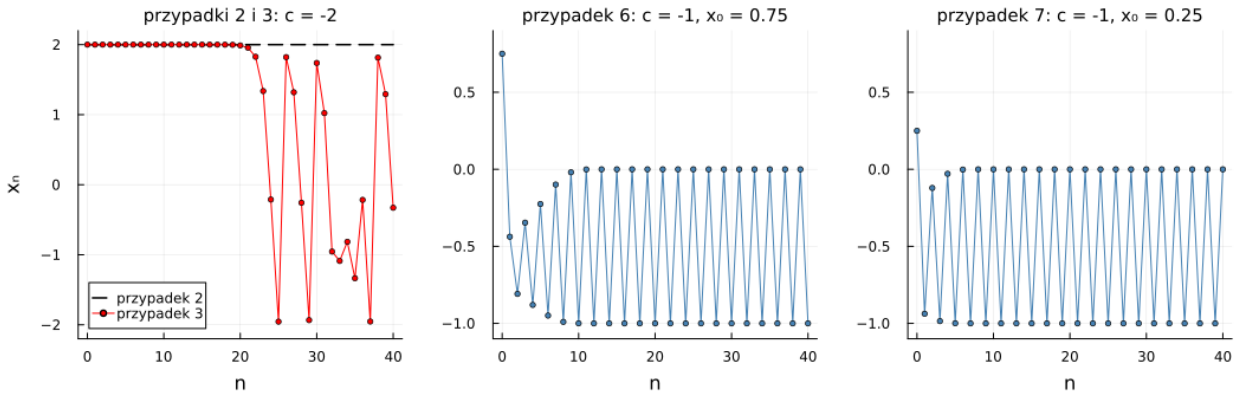
- Obcięcie p_{10} o $9.3 \cdot 10^{-4}$ wystarczyło, żeby ciągi się rozeszły. Od $n = 17$ różnica przekracza 0.1, a wartości p_{40} są zupełnie inne (0.259 i 1.094).
- Wartości p_0 w `Float32` i `Float64` różnią się o $2.2 \cdot 10^{-10}$, ponieważ 0.01 nie ma skończonego rozwinięcia dwójkowego. Dla $n = 10$ różnica wynosi już $1.6 \cdot 10^{-5}$, a od $n = 23$ przekracza 0.1.
- Wynik w `Float32` po 40 iteracjach nie ma żadnej poprawnej cyfry (błąd 0.25). Wynik w `Float64` jest jeszcze dobry, bo w porównaniu z `BigFloat` ($p_{40} = 0.0116116$) jego błąd wynosi $3.8 \cdot 10^{-7}$. Dla $n = 50$ błąd rośnie do $4.9 \cdot 10^{-4}$, a od $n = 57$ przekracza 0.1.
- Błąd rośnie mniej więcej dwukrotnie w każdej iteracji (w `Float64` od $1.8 \cdot 10^{-15}$ dla $n = 10$ do $3.8 \cdot 10^{-7}$ dla $n = 40$). Niewielkie błędy kumulują się, a większa precyzja tylko odsuwa moment utraty dokładności. Błąd przekracza 0.1 po około 23 iteracjach w `Float32` i po około 57 w `Float64`.

6 Zadanie 6

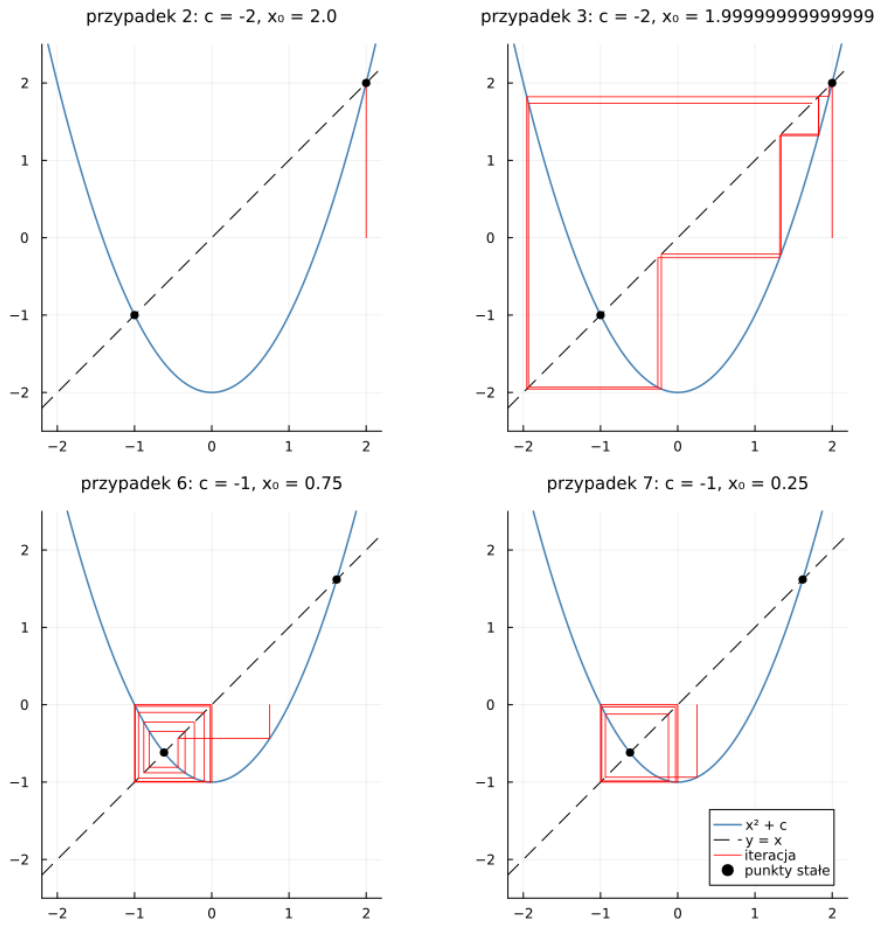
Wykonałem 40 iteracji w `Float64` dla siedmiu zestawów danych. Dla przypadków 2, 3, 6 i 7 narysowałem przebieg ciągu (rysunek 2) i iterację graficzną (rysunek 3). Przebieg przypadków 1, 4 i 5 jest prosty i widać go w tabeli.

Tabela 7: Zachowanie ciągów $x_{n+1} = x_n^2 + c$.

	(c, x_0)	**początek ciągu**	**koniec** $(n = 36, \ldots, 40)$
1	$(-2,\ 1)$	$1, -1, -1, \ldots$	-1 (punkt stały)
2	$(-2,\ 2)$	$2, 2, 2, \ldots$	2 (punkt stały)
3	$(-2,\ 1.99999999999999)$	blisko 2 do ok. $n = 20$	$-0.22, -1.95, 1.81, 1.29, -0.33$
4	$(-1,\ 1)$	$1, 0, -1, 0, -1, \ldots$	$-1, 0, -1, 0, -1$
5	$(-1,\ -1)$	$-1, 0, -1, 0, \ldots$	$-1, 0, -1, 0, -1$
6	$(-1,\ 0.75)$	$0.75, -0.44, -0.81, -0.35, -0.88, \ldots$	$-1, 0, -1, 0, -1$
7	$(-1,\ 0.25)$	$0.25, -0.94, -0.12, -0.99, -0.03, \ldots$	$0, -1, 0, -1, 0$



Rysunek 2: Wartości x_n dla $n = 0, \ldots, 40$.



Rysunek 3: Iteracja graficzna dla przypadków 2, 3, 6 i 7 (pierwsze 30 iteracji). Kropki to punkty stałe.

Interpretacja wyników

- Dla $c = -2$ punktami stałymi są 2 i -1. Oba są odpychające ($|f'(2)| = 4$, $|f'(-1)| = 2$), ale w przypadkach 1 i 2 wszystkie obliczenia są dokładne, więc ciąg trafia w punkt stały i już w nim zostaje.
- W przypadku 3 odległość od 2 wynosi początkowo 10^{-14} i rośnie około 4 razy w każdym kroku. Dla $n = 20$ mamy $x_n = 1.989$, dla $n = 22$ już 1.827, a dalej ciąg zachowuje się chaotycznie w przedziale $[-2, 2]$.
- Takie zachowanie wynika z samego odwzorowania, bo w `BigFloat` z tym samym x_0 ciąg przebiega tak samo (różnica $1.9 \cdot 10^{-7}$ dla $n = 30$ i $3.9 \cdot 10^{-4}$ dla $n = 40$). Błędy zaokrągleń też rosną, ale przez 40 iteracji nie zmieniają jeszcze przebiegu ciągu.
- Dla $c = -1$ punkty stałe $(1 \pm \sqrt{5})/2$ są odpychające ($|f'| \approx 3.24$ i 1.24), ale istnieje cykl $0 \to -1 \to 0$, który silnie przyciąga, ponieważ $f'(0)f'(-1) = 0$. Do tego cyklu dochodzą ciągi ze wszystkich przypadków od 4 do 7.
- W przypadku 5 ciąg od początku leży w cyklu, a w przypadku 4 wchodzi do niego po jednym kroku. W przypadkach 6 i 7 ciąg liczony dokładnie tylko zbliża się do cyklu, natomiast w `Float64` osiąga -1 dokładnie (odpowiednio dla $n = 16$ i $n = 11$), ponieważ odległość od 0 jest wtedy tak mała, że $x_n^2 - 1$ zaokrągla się do -1.